Fundamentals of AI and KR
Modulo 3 – Ragionamento probabilistico

Giovanni "Qua' Qua' dancer" Palma

Contents

Chapter 1 **Incertezza e probabilità** Page

1.1 Agire in condizioni di incertezza
Fonti di incertezza — • Metodi per gestire l'incertezza — • Interpretazioni della probabilità — • Decidere sotto incertezza —

1.2 Il linguaggio della probabilità
Spazi di probabilità — • Conseguenze degli assiomi — • Variabili aleatorie — • Variabili continue — • Probabilità a priori e congiunta — • Probabilità condizionata e chain rule —

Chapter 2 **Inferenza, indipendenza e regola di Bayes** Page

2.1 Inferenza con la distribuzione congiunta completa
Probabilità di una proposizione — • Marginalizzazione e normalizzazione — • Query ed enumerazione —

2.2 Indipendenza
Indipendenza marginale — • Indipendenza condizionata —

2.3 Regola di Bayes
Enunciato e uso diagnostico — • Combinare evidenze e Naive Bayes —

Chapter 3 **Reti bayesiane** Page

3.1 Rappresentazione e semantica
Sintassi — • Semantica globale — • Pattern di ragionamento — • Flusso di influenza e d-separazione — • Semantica locale e Markov blanket —

3.2 Costruzione e apprendimento
Costruzione da un ordinamento — • Esempi di modellazione — • Apprendere una rete dai dati — • Reti causali —

3.3 Rappresentazioni compatte ed estensioni
Distribuzioni canoniche — • Reti ibride — • Reti bayesiane dinamiche — • Oltre le reti bayesiane: reti di Markov —

Chapter 1

Incertezza e probabilità

Modulo 3 – R. Calegari, DISI, Università di Bologna. Riferimento: Russell & Norvig, *Artificial Intelligence: A Modern Approach*, 3ª ed., capitoli 13 (*Quantifying Uncertainty*) e 14 (*Probabilistic Reasoning*).

1.1 Agire in condizioni di incertezza

1.1.1 Fonti di incertezza

Definition 1.1.1: Agente sotto incertezza

Un agente opera **sotto incertezza** quando non può determinare con certezza lo stato del mondo o l'esito delle proprie azioni. Le cause tipiche sono:

(a) **osservabilità parziale**: informazioni rilevanti mancanti, ritardate o rumorose;

(b) **esiti incerti**: la stessa azione può portare a risultati diversi;

(c) **ambienti dinamici**: il mondo cambia mentre l'agente ragiona.

Un agente logico può rappresentare stati alternativi e piani di contingenza, ma in contesti realistici il numero di stati cresce rapidamente, i piani esaustivi diventano impraticabili e *nessuna azione garantisce il successo*.

Example 1.1.1 (L'aeroporto)

Sia A_t l'azione "partire per l'aeroporto t minuti prima del volo". A_t mi farà arrivare in tempo? I problemi sono: osservabilità parziale (stato delle strade, piani degli altri guidatori), sensori rumorosi (notiziari sul traffico), esiti incerti (gomma a terra), complessità enorme nel modellare il traffico. Un approccio puramente logico:

- o **rischia il falso**: "A_{25} mi porta in tempo";
- o produce conclusioni **troppo deboli** per decidere: "A_{25} mi porta in tempo *se* non ci sono incidenti sul ponte, *e* non piove, *e* le gomme reggono, ...".

(A_{1440} probabilmente funziona, ma costringe a dormire in aeroporto.)

Note:

Il secondo corno del dilemma è il **problema della qualificazione**: è impossibile elencare tutte le precondizioni di un'azione. Il libro elenca tre ragioni per cui la logica fallisce in domini come la diagnosi medica:

- **laziness** (pigrizia): è troppo costoso elencare tutti gli antecedenti e conseguenti necessari per una regola senza eccezioni;
- **theoretical ignorance**: la scienza stessa non ha una teoria completa del dominio;

- **practical ignorance**: anche conoscendo tutte le regole, per il singolo paziente non si sono fatti tutti i test.

La probabilità *riassume* l'incertezza dovuta a pigrizia e ignoranza.

1.1.2 Metodi per gestire l'incertezza

Definition 1.1.2: Approcci all'incertezza

1. **Logica di default / non monotona**: si assume ciò che è "normale" finché non è contraddetto ("assumo che A_{25} funzioni salvo evidenza contraria"). Problema: quali assunzioni sono ragionevoli?
2. **Sistemi a regole con pesi di confidenza**: regole del tipo $A_{25} \mapsto_{0.3} \mathit{AtAirportOnTime}$. Problemi di *località* (come può 0.3 tenere conto di *tutta* l'evidenza?) e di *combinazione* (concatenando $\mathit{FaultyPowerCord} \mapsto_{0.99} \mathit{DisplayOff}$ e $\mathit{DisplayOff} \mapsto_{0.7} \mathit{SleepMode}$ sembrerebbe che il cavo guasto causi lo sleep mode).
3. **Probabilità**: "data l'evidenza disponibile, A_{25} mi porta in tempo con probabilità 0.04".

Note:

Probabilità ≠ logica fuzzy.

- La probabilità modella l'**incertezza su un fatto**: $P(\mathit{Height} \geq 180) = 0.7$ — non conosco l'altezza di Alice.
- La logica fuzzy modella la **vaghezza di un concetto**: $\mu_{\mathit{Tall}}(\mathit{Alice}) = 0.7$ — so che Alice è alta 178 cm, ma "alto" non ha un confine netto.

1.1.3 Interpretazioni della probabilità

Definition 1.1.3: Interpretazione frequentista

La probabilità di un evento è la sua **frequenza relativa nel lungo periodo** in prove ripetute e comparabili. Es.: "nei viaggi simili, il 6% è arrivato in tempo".

Definition 1.1.4: Interpretazione bayesiana (soggettiva)

La probabilità esprime il **grado di credenza** di un agente in una proposizione, *data l'evidenza attualmente disponibile*. Es.:

$$P(\mathit{AtAirportOnTime} \mid A_{25}, \text{nessun incidente segnalato}) = 0.06.$$

Note:

Nel modulo si usa l'interpretazione bayesiana, perché un agente deve ragionare su una *singola* situazione, combinare evidenze e aggiornare le credenze. Conseguenze:

- 0.06 descrive lo stato di conoscenza dell'agente, *non* una proprietà intrinseca del viaggio;
- agenti con evidenze diverse possono assegnare probabilità diverse;
- nuova evidenza cambia la credenza: $P(\mathit{OnTime} \mid A_{25}, \text{no incidenti}, \text{ore } 5) = 0.15$.

1.1.4 Decidere sotto incertezza

Definition 1.1.5: Teoria delle decisioni

Le **preferenze** dell'agente sugli esiti sono rappresentate da una funzione di **utilità**. La

$$\text{teoria delle decisioni} = \text{teoria della probabilità} + \text{teoria dell'utilità}.$$

Un agente è **razionale** se segue il principio della **Massima Utilità Attesa** (MEU): sceglie l'azione con utilità attesa massima, mediata su tutti i possibili esiti dell'azione.

Example 1.1.2 (Scegliere A_t)

Supponiamo $P(A_{25}\text{ ok}) = 0.04$, $P(A_{90}\text{ ok}) = 0.70$, $P(A_{120}\text{ ok}) = 0.95$, $P(A_{1440}\text{ ok}) = 0.9999$. Quale azione scegliere dipende dalle preferenze (perdere il volo vs. mangiare in aeroporto): la probabilità da sola non basta, serve l'utilità.

1.2 Il linguaggio della probabilità

1.2.1 Spazi di probabilità

Sia la logica sia la probabilità ragionano su **mondi possibili**: la logica distingue i mondi possibili da quelli impossibili, la probabilità assegna a ciascun mondo un grado di plausibilità.

Definition 1.2.1: Spazio campionario, punto campionario, evento

- Lo **spazio campionario** Ω è l'insieme di tutti i mondi possibili.
- Ogni $\omega \in \Omega$ è un **punto campionario** (mondo possibile, evento atomico): un'assegnazione completa del mondo.
- Un **evento** è un sottoinsieme $A \subseteq \Omega$.

I mondi possibili sono **mutuamente esclusivi** (ne accade solo uno) ed **esaustivi** (uno di essi deve accadere).

Example 1.2.1 (Dado)

$\Omega = \{1, 2, 3, 4, 5, 6\}$; $\omega = 3$ è un punto campionario; $A = \{\omega \in \Omega \mid \omega < 4\} = \{1, 2, 3\}$ è un evento.

Definition 1.2.2: Spazio di probabilità

Uno **spazio di probabilità** è una tripla $(\Omega, \mathcal{F}, P)$ dove:

- Ω è lo spazio campionario;
- $\mathcal{F} \subseteq 2^{\Omega}$ è una **σ-algebra** di eventi (specifica a quali sottoinsiemi si può assegnare una probabilità);
- $P : \mathcal{F} \to [0, 1]$ è una **misura di probabilità** tale che $P(\Omega) = 1$ e, per eventi $A_1, A_2, \ldots$ a due a due disgiunti,

$$P\Big(\bigcup_{i=1}^{\infty} A_i\Big) = \sum_{i=1}^{\infty} P(A_i) \qquad (\sigma\text{-additività}).$$

Definition 1.2.3: Modello probabilistico discreto

Se Ω è finito o numerabile si prende $\mathcal{F} = 2^{\Omega}$ (ogni sottoinsieme è un evento). Un **modello probabilistico** assegna una probabilità $P(\omega)$ a ogni mondo, con

$$0 \le P(\omega) \le 1, \qquad \sum_{\omega \in \Omega} P(\omega) = 1,$$

e per ogni evento $A \subseteq \Omega$:

$$P(A) = \sum_{\omega \in A} P(\omega).$$

Example 1.2.2 (Dado equo)
$P(1) = \cdots = P(6) = \frac{1}{6}$, quindi $P(\text{dado} < 4) = P(1) + P(2) + P(3) = \frac{1}{2}$.

1.2.2 Conseguenze degli assiomi

Proposition 1.2.1 Probabilità della negazione
Per ogni proposizione a: $\quad P(\neg a) = 1 - P(a)$.

Dimostrazione: I mondi in cui vale $\neg a$ sono il complemento di quelli in cui vale a:

$$P(\neg a) = \sum_{\omega \in \neg a} P(\omega) = \sum_{\omega \in \neg a} P(\omega) + \sum_{\omega \in a} P(\omega) - \sum_{\omega \in a} P(\omega) = \sum_{\omega \in \Omega} P(\omega) - P(a) = 1 - P(a).$$

Proposition 1.2.2 Principio di inclusione–esclusione
Per ogni coppia di proposizioni a, b:

$$P(a \vee b) = P(a) + P(b) - P(a \wedge b).$$

Dimostrazione: I mondi di $a \vee b$ si partizionano in tre insiemi disgiunti: $a \wedge \neg b$, $\neg a \wedge b$, $a \wedge b$. Quindi $P(a \vee b) = P(a \wedge \neg b) + P(\neg a \wedge b) + P(a \wedge b)$. Inoltre $P(a) = P(a \wedge \neg b) + P(a \wedge b)$ e $P(b) = P(\neg a \wedge b) + P(a \wedge b)$. Sommando le ultime due si conta $P(a \wedge b)$ due volte; sottraendolo una volta si ottiene la tesi.

Note:
$P(\Omega) = 1$, $0 \le P \le 1$ e l'inclusione–esclusione sono detti **assiomi di Kolmogorov**: da essi si costruisce tutta la teoria. Essi *vincolano* le credenze su proposizioni logicamente legate, come in logica non si può credere a A, B e $\neg(A \wedge B)$ insieme.

Theorem 1.2.1 de Finetti (argomento della scommessa olandese)
Se un agente esprime gradi di credenza che **violano gli assiomi della probabilità**, allora esiste una combinazione di scommesse (accettabili secondo le sue stesse credenze) che gli fa **perdere denaro in ogni caso**, qualunque sia l'esito.

Example 1.2.3 (Credenze incoerenti)
L'Agente 1 crede $P(a) = 0.4$, $P(b) = 0.3$, $P(a \wedge b) = 0$, $P(a \vee b) = 0.8$ (viola l'inclusione–esclusione: $0.4 + 0.3 - 0 = 0.7 \neq 0.8$). L'Agente 2 scommette \$4 su a (4 a 6), \$3 su b (3 a 7), \$2 su $\neg(a \vee b)$ (2 a 8). Vincite per l'Agente 1:

Scommessa	a, b	$a, \neg b$	$\neg a, b$	$\neg a, \neg b$
a	-6	-6	4	4
b	-7	3	-7	3
$\neg(a \vee b)$	2	2	2	-8
Totale	-11	-1	-1	-1

L'Agente 1 perde in ogni mondo. Morale: nessun agente razionale può avere credenze che violano gli assiomi. ("Rifiutarsi di scommettere" non è una via d'uscita: ogni azione, anche l'inazione, è una scommessa.)

1.2.3 Variabili aleatorie

Definition 1.2.4: Variabile aleatoria

Una **variabile aleatoria** è una funzione

$$X : \Omega \to \mathcal{X}$$

che associa a ogni mondo possibile un valore del suo **dominio** $\mathcal{X}$ (reali, booleani, ...). Es.: $Odd(1) = true$.

Definition 1.2.5: Distribuzione di una variabile aleatoria

La misura P su Ω induce una **distribuzione di probabilità** per X che assegna una probabilità a ogni valore $x_i \in \mathcal{X}$:

$$P_X(x_i) = P(X = x_i) = P(\{\omega \in \Omega \mid X(\omega) = x_i\}), \qquad \sum_{x_i \in \mathcal{X}} P_X(x_i) = 1.$$

Si scrive in grassetto $\mathbf{P}(X)$ per il *vettore* di tutte le probabilità, es. $\mathbf{P}(Weather) = \langle 0.72, 0.10, 0.08, 0.10 \rangle$ per i valori $\langle sunny, cloudy, rainy, snowy \rangle$.

Example 1.2.4 (Dado e variabile Odd)

$P(Odd = true) = P(1) + P(3) + P(5) = \frac{1}{2}$, $P(Odd = false) = \frac{1}{2}$, quindi $\mathbf{P}(Odd) = \langle \frac{1}{2}, \frac{1}{2} \rangle$.

Definition 1.2.6: Proposizione come evento

Una proposizione denota l'**evento** formato da tutti i mondi possibili in cui è vera. Es. $Weather = rain$ è l'insieme dei mondi in cui la variabile $Weather$ vale $rain$. Per variabili booleane si abbrevia $a \equiv (A = true)$, $\neg a \equiv (A = false)$.

Definition 1.2.7: Tipi di variabili e proposizioni

- **Booleane**: $Cavity = true$, scritto $cavity$.
- **Discrete** (finite o infinite): $Weather \in \langle sunny, rain, cloudy, snow \rangle$; i valori devono essere **esaustivi e mutuamente esclusivi**.
- **Continue** (limitate o no): $Temp = 21.6$, $Temp < 22.0$.

Le proposizioni elementari si combinano con i connettivi booleani.

Proposition 1.2.3 Proposizione come disgiunzione di eventi atomici

Ogni proposizione è equivalente alla disgiunzione degli eventi atomici in cui è vera; essendo questi mutuamente esclusivi, la sua probabilità è la somma delle loro probabilità. Es. con $\Omega = \{a \wedge b, a \wedge \neg b, \neg a \wedge$

$b, \neg a \wedge \neg b\}$:

$$a \vee b \equiv (a \wedge b) \vee (a \wedge \neg b) \vee (\neg a \wedge b) \implies P(a \vee b) = P(a \wedge b) + P(a \wedge \neg b) + P(\neg a \wedge b).$$

1.2.4 Variabili continue

Note:

Intuizione (freccette). Una freccetta cade uniformemente su un bersaglio di raggio 10 cm. La probabilità di colpire *esattamente* il centro è 0 (un punto non ha area), ma non è impossibile. Ha senso chiedere la probabilità di una *regione*: $P(\text{dist}(L, \textit{centro}) \leq 1) = \frac{\pi \cdot 1^2}{\pi \cdot 10^2} = 0.01$. Per una variabile continua le probabilità riguardano **regioni**, non valori singoli.

Definition 1.2.8: Funzione di densità di probabilità (pdf)

Sia X una variabile continua con valori in $\mathcal{X}$. Una funzione non negativa e integrabile $p_X : \mathcal{X} \to \mathbb{R}_{\geq 0}$ è una **densità di probabilità** per X se

$$\int_{\mathcal{X}} p_X(x)\,dx = 1, \qquad \text{e} \qquad P(a \leq X \leq b) = \int_a^b p_X(x)\,dx.$$

Note:

$p_X(x)$ è una **densità**, non la probabilità del valore esatto x: per una variabile continua $P(X = x) = 0$, e $p_X(x)$ può anche essere > 1. Russell & Norvig scrivono comunque $P(X = x)$ per la densità (abuso di notazione), intendendo

$$P(X = x) := \lim_{\Delta x \to 0} \frac{P(x \leq X \leq x + \Delta x)}{\Delta x}.$$

Definition 1.2.9: Distribuzione uniforme

$X \sim \text{Unif}[a, b]$ se

$$p_X(x) = \begin{cases} \frac{1}{b-a} & a \leq x \leq b \\ 0 & \text{altrimenti.} \end{cases}$$

Es. $X \sim \text{Unif}[18, 26]$: $p_X(20.5) = \frac{1}{8} = 0.125$, cioè $P(20.5 \leq X \leq 20.5 + \Delta x) \approx 0.125\,\Delta x$.

Definition 1.2.10: Distribuzione gaussiana (normale)

$X \sim \mathcal{N}(\mu, \sigma^2)$ se

$$p_X(x) = \frac{1}{\sqrt{2\pi}\,\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}},$$

con media μ e deviazione standard σ. La **gaussiana standard** ha $\mu = 0$, $\sigma^2 = 1$: $p_X(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$.

1.2.5 Probabilità a priori e congiunta

Definition 1.2.11: Probabilità a priori

La probabilità **a priori** (o incondizionata) di una proposizione esprime la credenza dell'agente **prima** di incorporare nuova evidenza. Es. $\mathbf{P}(\textit{Weather}) = \langle 0.72, 0.10, 0.08, 0.10 \rangle$.

Definition 1.2.12: Distribuzione congiunta

La **distribuzione di probabilità congiunta** di un insieme di variabili assegna una probabilità a ogni **assegnazione completa** di valori a quelle variabili. Se le variabili sono *tutte* quelle del dominio si parla di **distribuzione congiunta completa** (full joint distribution).

Example 1.2.5 (**P**(*Weather*, *Cavity*))

È una tabella 4×2; ogni cella è un evento atomico:

	sunny	*rainy*	*cloudy*	*snowy*
Cavity = *true*	0.144	0.020	0.016	0.020
Cavity = *false*	0.576	0.080	0.064	0.080

$P(sunny) = 0.144 + 0.576 = 0.72$.

Note:

Un modello probabilistico è *completamente determinato* dalla distribuzione congiunta completa: ogni proposizione è un insieme di mondi, e ogni mondo è una cella della congiunta.

1.2.6 Probabilità condizionata e chain rule

Definition 1.2.13: Probabilità condizionata (a posteriori)

Per due proposizioni a, b con $P(b) \neq 0$:

$$P(a \mid b) = \frac{P(a \wedge b)}{P(b)}.$$

$P(a \mid b)$ è la credenza in a *sapendo che* b è vera. Quando b è evidenza appena osservata, $P(a \mid b)$ è detta probabilità **a posteriori**, e $P(a)$ è la corrispondente **a priori**.

Note:

- $P(cavity \mid toothache) = 0.8$ **non** è la regola logica $toothache \Rightarrow cavity$ "all'80%": dice solo che, *se l'unica cosa nota è* il mal di denti, la credenza è 0.8.
- Se poi si osserva anche *cavity*: $P(cavity \mid toothache, cavity) = 1$. Il valore 0.8 resta corretto, ma non è più quello utile.
- Evidenza *irrilevante* non cambia nulla: $P(cavity \mid toothache, 49ersWin) = P(cavity \mid toothache)$ (è un caso di indipendenza condizionata, vedi §2.2).

Definition 1.2.14: Distribuzione condizionata

$\mathbf{P}(X \mid Y)$ denota l'insieme delle distribuzioni $\mathbf{P}(X \mid Y = y)$, una per ogni valore y di Y. Es. $\mathbf{P}(Cavity \mid Toothache)$ è una tabella 2×2 (le righe sommano a 1):

	Cavity = *true*	*Cavity* = *false*
Toothache = *true*	0.8	0.2
Toothache = *false*	0.1	0.9

Proposition 1.2.4 Regola del prodotto

Per due proposizioni a, b:

$$P(a \wedge b) = P(a \mid b)\, P(b) = P(b \mid a)\, P(a).$$

In forma vettoriale, per ogni coppia di valori: $\mathbf{P}(X, Y) = \mathbf{P}(X \mid Y)\, \mathbf{P}(Y)$.

Dimostrazione: Immediata moltiplicando per $P(b)$ (risp. $P(a)$) la definizione di probabilità condizionata.

Note:

Applicando la regola del prodotto a ogni coppia (w, c) si costruisce tutta la congiunta $\mathbf{P}(\mathit{Weather}, \mathit{Cavity})$ (8 entrate) a partire da $\mathbf{P}(\mathit{Weather} \mid \mathit{Cavity})$ e $\mathbf{P}(\mathit{Cavity})$.

Theorem 1.2.2 Chain rule (regola della catena)

Per ogni insieme di variabili $X_1, \ldots, X_n$:

$$\mathbf{P}(X_1, \ldots, X_n) = \prod_{i=1}^{n} \mathbf{P}(X_i \mid X_1, \ldots, X_{i-1}),$$

dove per $i = 1$ l'insieme condizionante è vuoto: $\mathbf{P}(X_1 \mid \{\}) = \mathbf{P}(X_1)$.

Dimostrazione: Per induzione su n. Per $n = 1$ è banale. Supposto vero per $n - 1$, la regola del prodotto dà

$$\mathbf{P}(X_1, \ldots, X_n) = \mathbf{P}(X_n \mid X_1, \ldots, X_{n-1})\, \mathbf{P}(X_1, \ldots, X_{n-1}),$$

e per ipotesi induttiva $\mathbf{P}(X_1, \ldots, X_{n-1}) = \prod_{i=1}^{n-1} \mathbf{P}(X_i \mid X_1, \ldots, X_{i-1})$. Es. per $n = 3$: $\mathbf{P}(X_1, X_2, X_3) = \mathbf{P}(X_1)\, \mathbf{P}(X_2 \mid X_1)\, \mathbf{P}(X_3 \mid X_1, X_2)$.

Note:

La chain rule vale per **qualsiasi ordinamento** delle variabili ed è il punto di partenza della costruzione delle reti bayesiane (§3.2.1).

Chapter 2

Inferenza, indipendenza e regola di Bayes

2.1 Inferenza con la distribuzione congiunta completa

2.1.1 Probabilità di una proposizione

Definition 2.1.1: Inferenza probabilistica

L'**inferenza probabilistica** è il calcolo di probabilità a posteriori per proposizioni di interesse (*query*) data l'evidenza osservata. Se si conosce la congiunta completa, si risponde a qualsiasi query sommando le entrate dei mondi in cui la query è vera.

Esempio guida (dominio del dentista), con tre variabili booleane *Toothache*, *Catch* (la sonda si "impiglia"), *Cavity*:

	$toothache$		$\neg toothache$	
	$catch$	$\neg catch$	$catch$	$\neg catch$
$cavity$	0.108	0.012	0.072	0.008
$\neg cavity$	0.016	0.064	0.144	0.576

Proposition 2.1.1 Probabilità di una proposizione

Per ogni proposizione ϕ:

$$P(\phi) = \sum_{\omega \,:\, \omega \models \phi} P(\omega).$$

Example 2.1.1 (Query semplici)

- $P(toothache) = 0.108 + 0.012 + 0.016 + 0.064 = 0.2$;
- $P(cavity \vee toothache) = 0.108 + 0.012 + 0.072 + 0.008 + 0.016 + 0.064 = 0.28$;
- $P(\neg cavity \mid toothache) = \dfrac{P(\neg cavity \wedge toothache)}{P(toothache)} = \dfrac{0.016 + 0.064}{0.2} = 0.4.$

2.1.2 Marginalizzazione e normalizzazione

Definition 2.1.2: Marginalizzazione (summing out)

Per ottenere la distribuzione di un sottoinsieme di variabili $\mathbf{Y}$ si **somma** su tutti i valori delle altre variabili $\mathbf{Z}$:

$$\mathbf{P}(\mathbf{Y}) = \sum_{\mathbf{z}} \mathbf{P}(\mathbf{Y}, \mathbf{Z} = \mathbf{z}).$$

$\mathbf{P}(\mathbf{Y})$ è detta distribuzione **marginale**.

Proposition 2.1.2 Regola del condizionamento

Applicando la regola del prodotto alla marginalizzazione:

$$\mathbf{P}(\mathbf{Y}) = \sum_{\mathbf{z}} \mathbf{P}(\mathbf{Y} \mid \mathbf{z})\, P(\mathbf{z}).$$

(È la *formula delle probabilità totali*.)

Definition 2.1.3: Normalizzazione

Condizionare su $\mathbf{e}$ significa **scartare** i mondi incompatibili con l'evidenza e **riscalare** quelli rimasti affinché sommino a 1, preservandone i pesi relativi. La costante

$$\alpha = \frac{1}{P(\mathbf{e})}$$

è detta **costante di normalizzazione**; spesso non serve calcolare $P(\mathbf{e})$ esplicitamente: basta normalizzare il vettore finale.

Example 2.1.2 (Normalizzazione nel dominio del dentista)

Osservato *toothache*, i mondi compatibili hanno massa totale 0.2 (il restante 0.8 è scartato). Sommando su *Catch* (né osservata né interrogata):

$$\mathbf{P}(\mathit{Cavity} \mid \mathit{toothache}) = \alpha\, \mathbf{P}(\mathit{Cavity}, \mathit{toothache}) = \alpha\, \langle 0.108{+}0.012,\ 0.016{+}0.064 \rangle = 5\, \langle 0.12, 0.08 \rangle = \langle 0.6, 0.4 \rangle.$$

2.1.3 Query ed enumerazione

Definition 2.1.4: Query probabilistica

Sia $\mathbf{X}$ l'insieme di tutte le variabili. Una **query** chiede la distribuzione a posteriori

$$\mathbf{P}(\mathbf{Y} \mid \mathbf{E} = \mathbf{e})$$

dove $\mathbf{X}$ è partizionato in tre insiemi disgiunti:

- $\mathbf{Y}$: variabili di **query**;
- $\mathbf{E}$: variabili di **evidenza**, con valori osservati $\mathbf{e}$;
- $\mathbf{H} = \mathbf{X} \setminus (\mathbf{Y} \cup \mathbf{E})$: variabili **nascoste** (hidden).

Es. in $\mathbf{P}(\mathit{Cavity} \mid \mathit{Toothache} = \mathit{true})$: $\mathbf{Y} = \mathit{Cavity}$, $\mathbf{E} = \mathit{Toothache}$, $\mathbf{H} = \mathit{Catch}$.

Theorem 2.1.1 Inferenza per enumerazione

$$\mathbf{P}(\mathbf{Y} \mid \mathbf{E} = \mathbf{e}) = \alpha\, \mathbf{P}(\mathbf{Y}, \mathbf{E} = \mathbf{e}) = \alpha \sum_{\mathbf{h}} \mathbf{P}(\mathbf{Y}, \mathbf{E} = \mathbf{e}, \mathbf{H} = \mathbf{h}), \qquad \alpha = \frac{1}{P(\mathbf{E} = \mathbf{e})}.$$

I termini nella somma sono entrate della congiunta completa, perché $\mathbf{Y} \cup \mathbf{E} \cup \mathbf{H}$ copre tutte le variabili.

Dimostrazione: La prima uguaglianza è la definizione di probabilità condizionata; la seconda è la marginalizzazione sulle variabili nascoste $\mathbf{H}$.

Proposition 2.1.3 Algoritmo (enumerazione condizionata)

1. Fissa l'evidenza osservata $\mathbf{E} = \mathbf{e}$.
2. Per ogni valore $\mathbf{y}$ di $\mathbf{Y}$, somma le probabilità di tutti i mondi compatibili, variando le nascoste $\mathbf{H}$.
3. Normalizza con α affinché la distribuzione su $\mathbf{Y}$ sommi a 1.

Proposition 2.1.4 Complessità dell'enumerazione

Con n variabili, ciascuna con al più d valori, la congiunta ha fino a d^n entrate: spazio $O(d^n)$ per memorizzarla, tempo $O(d^n)$ nel caso peggiore per sommarla, e servono d^n numeri da stimare.

Note:

L'enumerazione non scala. Domanda che guida il resto del corso: *come rappresentare la congiunta in modo compatto e fare inferenza senza elencare tutti i mondi?* Risposta: **indipendenza** e **reti bayesiane**.

2.2 Indipendenza

2.2.1 Indipendenza marginale

Definition 2.2.1: Indipendenza marginale (assoluta)

Due eventi A e B sono **indipendenti**, scritto $A \perp\!\!\!\perp B$, se sapere se B accade non cambia la credenza in A:

$$P(A \mid B) = P(A) \quad (P(B) > 0).$$

Per variabili: $X \perp\!\!\!\perp Y$ se $\mathbf{P}(X \mid Y) = \mathbf{P}(X)$.

Proposition 2.2.1 Forme equivalenti dell'indipendenza

Se $P(A), P(B) > 0$ sono equivalenti:

$$\text{(i) } P(A \mid B) = P(A) \qquad \text{(ii) } P(B \mid A) = P(B) \qquad \text{(iii) } P(A \wedge B) = P(A)\,P(B).$$

Dimostrazione: (i)⇒(iii): $P(A \wedge B) = P(A \mid B)P(B) = P(A)P(B)$. (iii)⇒(ii): $P(B \mid A) = P(A \wedge B)/P(A) = P(A)P(B)/P(A) = P(B)$. (ii)⇒(i): $P(A \mid B) = P(B \mid A)P(A)/P(B) = P(A)$.

Example 2.2.1 (Il meteo non dipende dai denti)

Se $Weather \perp\!\!\!\perp (Toothache, Catch, Cavity)$:

$$\mathbf{P}(Toothache, Catch, Cavity, Weather) = \mathbf{P}(Toothache, Catch, Cavity)\,\mathbf{P}(Weather).$$

La congiunta ha $2 \cdot 2 \cdot 2 \cdot 4 = 32$ entrate, cioè 31 parametri liberi. Fattorizzata: $(2^3 - 1) + (4 - 1) = 7 + 3 = 10$ parametri liberi (12 numeri memorizzati invece di 32).

Corollary 2.2.1 Variabili mutuamente indipendenti

Con n variabili booleane mutuamente indipendenti bastano n parametri invece di $2^n - 1$.

Note:

L'indipendenza marginale è potente ma **rara**: in odontoiatria ci sono centinaia di variabili e nessuna è indipendente dalle altre. Serve una nozione più debole: l'indipendenza *condizionata*.

2.2.2 Indipendenza condizionata

Definition 2.2.2: Indipendenza condizionata

X e Y sono **condizionatamente indipendenti dato** Z, scritto $X \perp\!\!\!\perp Y \mid Z$, se, una volta noto Z, conoscere Y non cambia la distribuzione di X:

$$\mathbf{P}(X \mid Y, Z) = \mathbf{P}(X \mid Z).$$

Proposition 2.2.2 Forme equivalenti dell'indipendenza condizionata

Sono equivalenti:

$$\text{(i) } \mathbf{P}(X \mid Y, Z) = \mathbf{P}(X \mid Z) \qquad \text{(ii) } \mathbf{P}(Y \mid X, Z) = \mathbf{P}(Y \mid Z) \qquad \text{(iii) } \mathbf{P}(X, Y \mid Z) = \mathbf{P}(X \mid Z)\,\mathbf{P}(Y \mid Z).$$

Dimostrazione: È la stessa dimostrazione del caso marginale, applicata alla misura $P(\cdot \mid Z = z)$ per ogni valore z: ad es. (i)⇒(iii) perché $\mathbf{P}(X, Y \mid Z) = \mathbf{P}(X \mid Y, Z)\,\mathbf{P}(Y \mid Z) = \mathbf{P}(X \mid Z)\,\mathbf{P}(Y \mid Z)$.

Example 2.2.2 (Dentista: $Catch \perp\!\!\!\perp Toothache \mid Cavity$)

Sapendo se c'è una carie, sapere del mal di denti non dice nulla in più sul fatto che la sonda si impigli (entrambi sono *effetti* della carie). **Verifica numerica sulla tabella**: $P(cavity) = 0.2$, $P(toothache \mid cavity) = 0.12/0.2 = 0.6$, $P(catch \mid cavity) = 0.18/0.2 = 0.9$ e

$$P(toothache, catch \mid cavity) = \frac{0.108}{0.2} = 0.54 = 0.6 \cdot 0.9. \checkmark$$

Attenzione: *Catch* e *Toothache* sono **dipendenti** marginalmente; diventano indipendenti solo condizionando su *Cavity*.

Proposition 2.2.3 Fattorizzazione con indipendenza condizionata

Chain rule + $Catch \perp\!\!\!\perp Toothache \mid Cavity$:

$$\begin{aligned}\mathbf{P}(Cavity, Toothache, Catch) &= \mathbf{P}(Cavity)\,\mathbf{P}(Toothache \mid Cavity)\,\mathbf{P}(Catch \mid Toothache, Cavity) \\ &= \mathbf{P}(Cavity)\,\mathbf{P}(Toothache \mid Cavity)\,\mathbf{P}(Catch \mid Cavity).\end{aligned}$$

Parametri liberi: $1 + 2 + 2 = 5$ invece di $2^3 - 1 = 7$.

Note:

L'indipendenza condizionata cattura la **rilevanza locale**: una volta note le variabili direttamente rilevanti, le altre non aggiungono informazione. Nella maggior parte dei casi riduce la rappresentazione della congiunta da **esponenziale** a **lineare** in n. È la forma di conoscenza più basilare e robusta sugli ambienti incerti.

2.3 Regola di Bayes

2.3.1 Enunciato e uso diagnostico

Note:

I test medici sono descritti da $P(+ \mid \textit{Disease})$ (probabilità che il test sia positivo se c'è la malattia), ma dopo un test positivo interessa $P(\textit{Disease} \mid +)$. Le due quantità **non coincidono**: la regola di Bayes permette di *invertire* il condizionamento.

Theorem 2.3.1 Regola di Bayes

Per due eventi A, B con $P(B) > 0$:

$$P(A \mid B) = \frac{P(B \mid A)\, P(A)}{P(B)}.$$

Per variabili, sull'intera distribuzione a posteriori di Y dato $X = x$:

$$\mathbf{P}(Y \mid X = x) = \alpha\, P(X = x \mid Y)\, \mathbf{P}(Y), \qquad \alpha = \frac{1}{P(X = x)}.$$

Dimostrazione: Dalla regola del prodotto scritta nei due modi, $P(A \wedge B) = P(A \mid B)P(B) = P(B \mid A)P(A)$; si divide per $P(B)$.

Note:

Lettura: $\underbrace{P(A \mid B)}_{\text{posterior}} = \frac{\overbrace{P(B \mid A)}^{\text{verosimiglianza}}\ \overbrace{P(A)}^{\text{prior}}}{\underbrace{P(B)}_{\text{evidenza}}}$. Bayes aggiorna la credenza a priori $P(A)$ dopo aver osservato B, pesandola con quanto l'osservazione è compatibile con A.

Corollary 2.3.1 Bayes con conoscenza di sfondo

Condizionando tutto su un'evidenza di sfondo $\mathbf{e}$:

$$\mathbf{P}(Y \mid X, \mathbf{e}) = \frac{\mathbf{P}(X \mid Y, \mathbf{e})\, \mathbf{P}(Y \mid \mathbf{e})}{\mathbf{P}(X \mid \mathbf{e})}.$$

Example 2.3.1 (Meningite)

M: "il paziente ha la meningite", S: "ha il collo rigido". Noti $P(M) = 1/50000$, $P(S) = 0.01$, $P(S \mid M) = 0.7$:

$$P(M \mid S) = \frac{P(S \mid M)\, P(M)}{P(S)} = \frac{0.7 \cdot 1/50000}{0.01} = 0.0014.$$

Il prior conta: anche se il 70% dei malati ha il collo rigido, la meningite è rarissima; l'osservazione alza la probabilità da 0.002% a 0.14%, che resta bassa.

Note:

Perché Bayes è utile in pratica. La conoscenza *causale* $P(\textit{effetto} \mid \textit{causa})$ è più robusta di quella *diagnostica* $P(\textit{causa} \mid \textit{effetto})$. Se scoppia un'epidemia di meningite, $P(M)$ sale e $P(M \mid S)$ deve cambiare; ma $P(S \mid M)$ (come la malattia agisce) resta invariata. Chi ha memorizzato solo $P(M \mid S)$ non sa aggiornarla; chi usa Bayes sì.

2.3.2 Combinare evidenze e Naive Bayes

Proposition 2.3.1 Bayes con evidenze condizionatamente indipendenti

Se $Toothache \perp\!\!\!\perp Catch \mid Cavity$:

$$\begin{aligned}\mathbf{P}(Cavity \mid toothache, catch) &= \alpha\, \mathbf{P}(toothache, catch \mid Cavity)\, \mathbf{P}(Cavity) \\ &= \alpha\, \mathbf{P}(toothache \mid Cavity)\, \mathbf{P}(catch \mid Cavity)\, \mathbf{P}(Cavity).\end{aligned}$$

Non serve specificare una probabilità per ogni combinazione di osservazioni.

Example 2.3.2 (Calcolo esplicito)

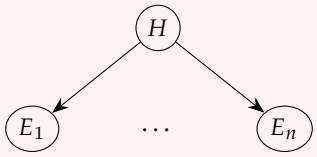
Dalla tabella: $P(toothache \mid \neg cavity) = 0.08/0.8 = 0.1$, $P(catch \mid \neg cavity) = 0.16/0.8 = 0.2$. Quindi

$$\mathbf{P}(Cavity \mid toothache, catch) = \alpha\, \langle 0.6 \cdot 0.9 \cdot 0.2,\ 0.1 \cdot 0.2 \cdot 0.8 \rangle = \alpha\, \langle 0.108, 0.016 \rangle \approx \langle 0.871, 0.129 \rangle.$$

Definition 2.3.1: Modello Naive Bayes

Un modello **naive Bayes** ha una variabile ipotesi (causa) H e variabili di osservazione (effetti) $E_1, \ldots, E_n$, assunte **condizionatamente indipendenti dato** H:

$$\mathbf{P}(H, E_1, \ldots, E_n) = \mathbf{P}(H) \prod_{i=1}^{n} \mathbf{P}(E_i \mid H).$$



Proposition 2.3.2 Parametri del Naive Bayes

Se H ha k valori e ogni E_i ne ha al più r, il modello richiede

$$(k-1) + n\,k\,(r-1)$$

parametri liberi: **lineare** in n (per k, r fissati). Es. dentista: $H = Cavity$, $E_1 = Toothache$, $E_2 = Catch$: $1 + 2 \cdot 2 \cdot 1 = 5$.

Note:

Si chiama "naive" perché viene usato anche quando l'indipendenza condizionata degli effetti *non* è vera; nonostante ciò funziona spesso sorprendentemente bene (es. classificazione di testi/spam).

Chapter 3

Reti bayesiane

3.1 Rappresentazione e semantica

3.1.1 Sintassi

3.1.1.1 Grafi diretti aciclici

Definition 3.1.1: Grafo diretto aciclico (DAG)

Un **DAG** è un grafo con archi orientati in cui è impossibile partire da un nodo e tornarci seguendo il verso delle frecce (nessun ciclo *diretto*). Un triangolo $A \to B$, $A \to C$, $B \to C$ è un DAG: il grafo non orientato sottostante ha un ciclo, ma seguendo le frecce non si torna mai indietro. $A \to B \to C \to A$ invece non lo è.

Lenma 3.1.1 Ordinamento topologico

Ogni DAG finito ammette un **ordinamento topologico**: un ordinamento $X_1, \dots, X_n$ dei nodi tale che ogni arco va da un nodo precedente a uno successivo, cioè $Parents(X_i) \subseteq \{X_1, \dots, X_{i-1}\}$.

Dimostrazione: Un DAG finito non vuoto ha almeno un nodo senza archi entranti (una *radice*): altrimenti, risalendo gli archi all'indietro da un nodo qualunque, dopo al più n passi si rivisita un nodo, trovando un ciclo diretto. Si mette la radice per prima, la si rimuove (il grafo resta un DAG) e si procede per induzione sui nodi rimanenti.

Note:

L'aciclicità serve proprio a questo: permette di ordinare le variabili in modo che la probabilità di ogni nodo sia specificata solo in funzione di variabili che vengono prima.

3.1.1.2 Definizione di rete bayesiana

Definition 3.1.2: Rete bayesiana (sintassi)

Una **rete bayesiana** su variabili $X_1, \dots, X_n$ consiste di:

- un **nodo** per ogni variabile;
- un **DAG** sui nodi;
- per ogni nodo, una **distribuzione condizionata locale** $\mathbf{P}(X_i \mid Parents(X_i))$.

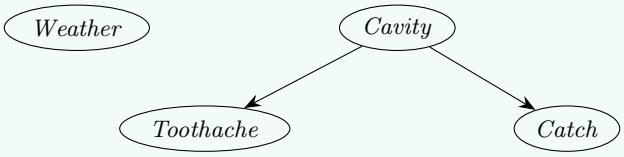
Un arco $X_j \to X_i$ significa che X_j è **genitore** di X_i: rappresenta una dipendenza probabilistica diretta ("influenza direttamente"), **non** necessariamente una relazione causale. La topologia codifica asserzioni di indipendenza condizionata.

Definition 3.1.3: Tabella di probabilità condizionata (CPT)

Se le variabili sono discrete, ogni distribuzione locale è una **CPT**: per ogni combinazione di valori dei genitori, una riga dà una distribuzione sui valori di X_i. Un nodo senza genitori ha come CPT la sua probabilità a priori.

3.1.1.3 Esempi

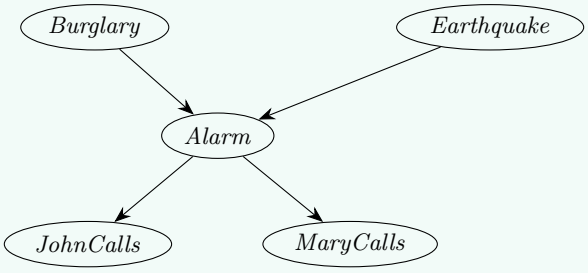
Example 3.1.1 (Rete del dentista)



Weather è indipendente dalle altre; *Toothache* e *Catch* sono condizionatamente indipendenti dato *Cavity*.

Example 3.1.2 (Rete dell'allarme (Burglary network))

Sono al lavoro; il vicino John chiama dicendo che l'allarme suona; la vicina Mary non chiama. L'allarme può scattare per un furto, ma a volte anche per un piccolo terremoto. Vogliamo $P(Burglary \mid JohnCalls = true, MaryCalls = false)$.



$P(b)$
0.001

$P(e)$
0.002

B	E	$P(a \mid B, E)$
T	T	0.95
T	F	0.94
F	T	0.29
F	F	0.001

A	$P(j \mid A)$
T	0.90
F	0.05

A	$P(m \mid A)$
T	0.70
F	0.01

Le probabilità *riassumono* un insieme potenzialmente infinito di circostanze: Mary che ascolta musica alta e non sente l'allarme, John che confonde il telefono con l'allarme, ecc. — senza modellarle.

3.1.2 Semantica globale

3.1.2.1 Fattorizzazione della congiunta

Definition 3.1.4: Semantica globale di una rete bayesiana

Le distribuzioni locali definiscono la **distribuzione congiunta completa** come loro prodotto:

$$P(x_1, \ldots, x_n) = \prod_{i=1}^{n} P\left(x_i \mid pa_i\right),$$

dove pa_i sono i valori assegnati ai genitori di X_i nell'assegnazione completa $(x_1, \ldots, x_n)$. **Lettura**: per un'assegnazione completa si sceglie una entry dalla CPT di ogni nodo e si moltiplicano.

Example 3.1.3 (Un evento atomico nella rete dell'allarme)

"L'allarme suona, John e Mary chiamano, nessun furto né terremoto":

$$\begin{aligned} P(j, m, a, \neg b, \neg e) &= P(j \mid a)\, P(m \mid a)\, P(a \mid \neg b, \neg e)\, P(\neg b)\, P(\neg e) \\ &= 0.9 \cdot 0.7 \cdot 0.001 \cdot 0.999 \cdot 0.998 \approx 0.00063. \end{aligned}$$

La rete ricostruisce ogni evento atomico dalle CPT senza memorizzare la congiunta.

Note:

Ne segue che una rete bayesiana può rispondere a *qualsiasi* query, sommando le entrate rilevanti della congiunta (inferenza per enumerazione, eventualmente reso efficiente — prossimo argomento).

3.1.2.2 Compattezza

Proposition 3.1.1 Compattezza

Una CPT per una X_i booleana con k genitori booleani ha 2^k righe, ognuna con un solo numero p (l'altro è $1 - p$). Se ogni nodo ha al più k genitori, la rete richiede

$$O(n \cdot 2^k) \quad \text{numeri, contro} \quad O(2^n) \text{ della congiunta completa:}$$

cresce **linearmente** in n.

Example 3.1.4 (Conteggio dei parametri)

- Rete dell'allarme: $1 + 1 + 4 + 2 + 2 = 10$ numeri contro $2^5 - 1 = 31$.
- Rete dello studente (sotto): $1 + 1 + 8 + 2 + 3 = 15$ contro $2^4 \cdot 3 - 1 = 47$.
- $n = 30$ nodi con $k = 5$ genitori: $30 \cdot 2^5 = 960$ numeri contro $2^{30} \approx 10^9$.

Definition 3.1.5: Sistema localmente strutturato

Un sistema è **localmente strutturato** (o *sparso*) se ogni componente interagisce direttamente solo con un numero limitato di altre componenti. Le reti bayesiane sono compatte proprio per questa proprietà, tipica dei domini reali; la complessità cresce linearmente invece che esponenzialmente.

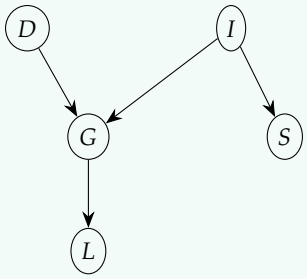
3.1.3 Pattern di ragionamento

L'inferenza **non** deve seguire il verso delle frecce: si può ragionare dalle cause agli effetti, dalle osservazioni alle spiegazioni, o tra spiegazioni alternative.

3.1.3.1 La rete dello studente

Example 3.1.5 (La rete dello studente)

Il voto (*Grade*) dipende dall'intelligenza dello studente (*Intelligence*) e dalla difficoltà del corso (*Difficulty*). Il punteggio *SAT* è correlato all'intelligenza. Il professore scrive la lettera di referenze (*Letter*) guardando solo il voto.



3.1.3.2 Tre tipi di ragionamento

Definition 3.1.6: Ragionamento predittivo (causale)

Si predice un effetto a partire da cause note, nel verso delle frecce. Es. $P(\textit{Letter} = \textit{strong})$: 0.50 a priori; 0.39 se $I = \textit{normal}$; 0.51 se inoltre $D = \textit{easy}$.

Definition 3.1.7: Ragionamento diagnostico (evidenziale)

Si inferisce una spiegazione non osservata a partire dall'evidenza, contro il verso delle frecce. Es. $P(I = \textit{superior})$: 0.30 a priori; 0.08 se $G = \textit{poor}$; 0.14 se $L = \textit{weak}$; 0.08 con entrambi; 0.58 se si aggiunge $S = \textit{high}$.

Definition 3.1.8: Ragionamento intercausale (explaining away)

Osservato un effetto comune, l'evidenza su una causa **modifica** la credenza nell'altra causa. Es. con $G = \textit{poor}$: $P(I = \textit{superior}) = 0.08$; se si scopre anche $D = \textit{hard}$ sale a 0.11 (il voto basso è "spiegato" dalla difficoltà). Con $G = \textit{good}$: 0.17, e con $D = \textit{hard}$ sale a 0.34.

3.1.4 Flusso di influenza e d-separazione

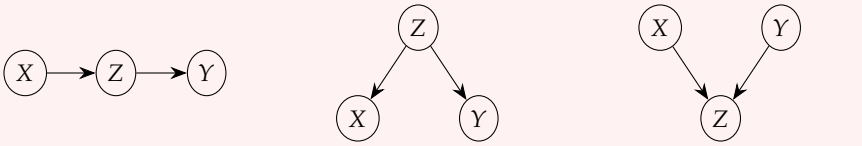
3.1.4.1 Trail e pattern di base

Definition 3.1.9: Trail

Un **trail** è un cammino nella rete che segue nodi connessi **ignorando il verso degli archi**: $X_1 \rightleftharpoons \cdots \rightleftharpoons X_n$.

Per capire se due variabili possono dipendere probabilisticamente data l'evidenza, ci si chiede se esiste un **trail attivo** tra loro. Il caso base è il trail di due archi $X \rightleftharpoons Z \rightleftharpoons Y$:

Definition 3.1.10: I tre pattern di base



catena | causa comune | effetto comune (v-structure)

	Catena $X \to Z \to Y$	Causa comune $X \leftarrow Z \to Y$	Effetto comune $X \to Z \leftarrow Y$
Ruolo di Z	non-collider	non-collider	**collider**
Z non osservato	attivo	attivo	**bloccato**
Z osservato	bloccato	bloccato	**attivo**

Osservare un nodo intermedio ordinario **blocca** il trail; osservare un collider (o un suo discendente) lo **apre**.

Example 3.1.6 (Intuizioni sui tre pattern)

- **Catena** *Rain* $\to$ *WetGrass* $\to$ *SlipperyPath*: se non so se l'erba è bagnata, sapere che è piovuto cambia la credenza sul sentiero scivoloso; se so che l'erba è bagnata, la pioggia non aggiunge nulla: $Rain \perp\!\!\!\perp SlipperyPath \mid WetGrass$.
- **Causa comune** *IceCreamSales* $\leftarrow$ *HotWeather* $\to$ *SunglassesSales*: vendite alte di gelati rendono più plausibile il caldo e quindi le vendite di occhiali; noto il caldo, i gelati non dicono più nulla sugli occhiali.
- **Effetto comune** *Burglary* $\to$ *Alarm* $\leftarrow$ *Earthquake*: furto e terremoto sono indipendenti; osservato l'allarme, confermare il furto rende meno necessario il terremoto per spiegarlo (*explaining away*).

3.1.4.2 Trail attivi e d-separazione

Definition 3.1.11: Trail attivo

Sia $\mathbf{Z}$ un insieme di variabili osservate. Un trail $X_1 \rightleftharpoons \cdots \rightleftharpoons X_n$ è **attivo dato $\mathbf{Z}$** se ogni nodo interno X_i soddisfa:

- se $X_{i-1} \to X_i \leftarrow X_{i+1}$ (collider), allora X_i **o un suo discendente** appartiene a $\mathbf{Z}$;
- altrimenti (non-collider), $X_i \notin \mathbf{Z}$.

Definition 3.1.12: Nodo bloccato

Dato $\mathbf{Z}$, un nodo intermedio di un trail è **bloccato** se:

- è il centro di una v-structure *non marcata* (collider tale che né esso né alcun discendente è osservato); oppure
- è un non-collider che appartiene a $\mathbf{Z}$.

Un trail è attivo se e solo se nessun suo nodo interno è bloccato.

Definition 3.1.13: d-separazione

Due insiemi di nodi $\mathbf{X}$, $\mathbf{Y}$ sono **d-separati** dato $\mathbf{Z}$ se non esiste alcun trail attivo, dato $\mathbf{Z}$, tra un $X \in \mathbf{X}$ e un $Y \in \mathbf{Y}$.

Theorem 3.1.1 Correttezza della d-separazione

Per ogni distribuzione P rappresentata dalla rete bayesiana:

$$\mathbf{X} \text{ e } \mathbf{Y} \text{ d-separati dato } \mathbf{Z} \implies P \models \mathbf{X} \perp\!\!\!\perp \mathbf{Y} \mid \mathbf{Z}.$$

Note:

Il viceversa vale solo in senso debole: se $\mathbf{X}$ e $\mathbf{Y}$ *non* sono d-separati, esiste *qualche* distribuzione compatibile con il grafo in cui sono dipendenti (ma per CPT particolari potrebbero essere indipendenti "per caso"). La d-separazione legge le indipendenze *garantite dalla struttura*.

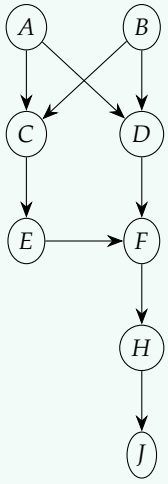
Proposition 3.1.2 Algoritmo per verificare $X \perp\!\!\!\perp Y \mid \mathbf{Z}$

1. Percorri il grafo dal basso verso l'alto **marcando** tutti i nodi in $\mathbf{Z}$ o che hanno discendenti in $\mathbf{Z}$.
2. Percorri il grafo da X verso Y, fermandoti quando incontri un nodo bloccato.
3. Se non puoi raggiungere Y, allora X e Y sono indipendenti dato $\mathbf{Z}$.

3.1.4.3 Esempi

Example 3.1.7 (d-separazione guidata)

Rete: $A \to C$, $A \to D$, $B \to C$, $B \to D$, $C \to E$, $E \to F$, $D \to F$, $F \to H$, $H \to J$. Ci chiediamo se C e D sono d-separati.



Trail rilevanti: $T_1 : C \leftarrow A \to D$; $T_2 : C \leftarrow B \to D$; $T_3 : C \to E \to F \leftarrow D$ (collider in F).

1. $\mathbf{Z} = \emptyset$: **dipendenti** (T_1, T_2 attivi; T_3 bloccato in F).
2. $\mathbf{Z} = \{A\}$: **dipendenti** (T_1 bloccato, ma T_2 attivo).
3. $\mathbf{Z} = \{A, B\}$: **indipendenti** (T_1, T_2 bloccati; T_3 bloccato nel collider F non osservato).
4. $\mathbf{Z} = \{A, B, J\}$: **dipendenti** (J è discendente di F: osservarlo apre il collider, T_3 diventa attivo).
5. $\mathbf{Z} = \{A, B, E, J\}$: **indipendenti** ($T_3$ è aperto in F ma bloccato dal non-collider osservato E).

Example 3.1.8 (Indipendenze della rete dello studente)

Leggendo la d-separazione sul grafo $D \to G \leftarrow I \to S$, $G \to L$:

$$L \perp\!\!\!\perp \{I, D, S\} \mid G, \quad S \perp\!\!\!\perp \{G, D, L\} \mid I, \quad G \perp\!\!\!\perp S \mid I, \quad I \perp\!\!\!\perp D, \quad D \perp\!\!\!\perp \{I, S\}.$$

3.1.5 Semantica locale e Markov blanket

3.1.5.1 Proprietà di Markov locale

Definition 3.1.14: Semantica locale (proprietà di Markov locale)

Ogni nodo X è condizionatamente indipendente dai suoi **non-discendenti**, dati i suoi **genitori**:

$$X \perp\!\!\!\perp \big(NonDescendants(X) \setminus Parents(X)\big) \mid Parents(X).$$

Per valutare quanto è probabile un nodo basta conoscere i genitori diretti. Es. $JohnCalls \perp\!\!\!\perp Burglary \mid Alarm$.

Lenma 3.1.2 Insiemi ancestrali

Sia $\mathbf{A}$ un insieme di nodi **ancestrale** (chiuso rispetto ai genitori: se $X \in \mathbf{A}$ allora $Parents(X) \subseteq \mathbf{A}$). Se vale la semantica globale, allora

$$P(\mathbf{a}) = \prod_{X_i \in \mathbf{A}} P(x_i \mid pa_i).$$

Dimostrazione: Si sommano via i nodi fuori da $\mathbf{A}$ in ordine topologico *inverso*. Ad ogni passo il nodo eliminato X_k è una foglia rispetto ai nodi rimasti, quindi compare in un solo fattore, la sua CPT, e $\sum_{x_k} P(x_k \mid pa_k) = 1$. Nessun nodo di $\mathbf{A}$ ha come genitore un nodo eliminato (perché $\mathbf{A}$ è ancestrale), quindi i fattori di $\mathbf{A}$ restano intatti.

Theorem 3.1.2 Semantica locale ⇔ semantica globale

Per un DAG G e una distribuzione P sulle sue variabili, sono equivalenti:

(i) P si fattorizza secondo G: $P(x_1, \dots, x_n) = \prod_i P(x_i \mid pa_i)$;

(ii) P soddisfa la proprietà di Markov locale per ogni nodo di G.

Dimostrazione: **(ii)⇒(i).** Si prende un ordinamento topologico (Lemma sull'ordinamento topologico) e si applica la chain rule: $P(x_1, \dots, x_n) = \prod_i P(x_i \mid x_1, \dots, x_{i-1})$. I predecessori $X_1, \dots, X_{i-1}$ sono tutti non-discendenti di X_i e contengono $Parents(X_i)$; per la proprietà locale $P(x_i \mid x_1, \dots, x_{i-1}) = P(x_i \mid pa_i)$.
(i)⇒(ii). Sia $\mathbf{N}$ l'insieme dei non-discendenti di X. L'insieme $\mathbf{A} = \mathbf{N} \cup \{X\}$ è ancestrale: i genitori di X non sono suoi discendenti, e se un genitore di $Y \in \mathbf{N}$ fosse discendente di X, lo sarebbe anche Y. Per il lemma sugli insiemi ancestrali,

$$P(x, \mathbf{n}) = P(x \mid pa_X) \prod_{Y \in \mathbf{N}} P(y \mid pa_Y),$$

e i fattori su $\mathbf{N}$ non contengono x. Quindi

$$P(x \mid \mathbf{n}) = \frac{P(x \mid pa_X) \prod_{\mathbf{N}}(\cdots)}{\sum_{x'} P(x' \mid pa_X) \prod_{\mathbf{N}}(\cdots)} = P(x \mid pa_X),$$

che dipende da $\mathbf{n}$ solo attraverso pa_X.

3.1.5.2 Markov blanket

Definition 3.1.15: Markov blanket

Il **Markov blanket** $MB(X)$ di un nodo X è formato da:

- i **genitori** di X;
- i **figli** di X;
- gli **altri genitori dei figli** di X.

Es. $MB(Alarm) = \{Burglary, Earthquake, JohnCalls, MaryCalls\}$ (qui i figli non hanno altri genitori).

Theorem 3.1.3 Proprietà del Markov blanket

Dato il suo Markov blanket, X è condizionatamente indipendente da *tutti* gli altri nodi della rete:

$$X \perp\!\!\!\perp \big(\mathbf{V} \setminus (\{X\} \cup MB(X))\big) \mid MB(X).$$

Dimostrazione: Per la semantica globale, condizionando su tutte le altre variabili $\mathbf{v}_{-X}$:

$$P(x \mid \mathbf{v}_{-X}) = \frac{\prod_i P(x_i \mid pa_i)}{\sum_{x'} \prod_i P(x_i \mid pa_i)\big|_{x=x'}}.$$

I fattori che *non* contengono x si semplificano tra numeratore e denominatore. Restano solo la CPT di X e quelle dei suoi figli Y_j:

$$P(x \mid \mathbf{v}_{-X}) = \alpha\, P(x \mid pa_X) \prod_{Y_j \in Children(X)} P(y_j \mid pa_{Y_j}),$$

che dipende solo da genitori di X, figli e genitori dei figli, cioè da $MB(X)$.

Note:

Il Markov blanket è il **più piccolo** insieme locale che contiene tutta l'informazione su un nodo disponibile nella rete. La formula nella dimostrazione è alla base dei metodi di campionamento come il *Gibbs sampling*.

3.2 Costruzione e apprendimento

3.2.1 Costruzione da un ordinamento

3.2.1.1 Procedura e correttezza

Definition 3.2.1: Costruzione da un ordinamento

1. Scegli un ordinamento delle variabili $X_1, \dots, X_n$.
2. Per $i = 1, \dots, n$:
   - aggiungi X_i alla rete;
   - scegli $Parents(X_i) \subseteq \{X_1, \dots, X_{i-1}\}$ **minimale** tale che

     $$X_i \perp\!\!\!\perp \big(\{X_1, \dots, X_{i-1}\} \backslash Parents(X_i)\big) \mid Parents(X_i), \quad \text{cioè} \quad \mathbf{P}(X_i \mid X_1, \dots, X_{i-1}) = \mathbf{P}(X_i \mid Parents(X_i));$$

   - aggiungi gli archi $Parents(X_i) \to X_i$ e scrivi la CPT $\mathbf{P}(X_i \mid Parents(X_i))$.

Theorem 3.2.1 Correttezza della costruzione

La rete ottenuta è un DAG e rappresenta esattamente la congiunta:

$$\mathbf{P}(X_1, \dots, X_n) = \prod_{i=1}^{n} \mathbf{P}(X_i \mid Parents(X_i)).$$

Dimostrazione: **Aciclicità**: ogni arco va da X_j a X_i con $j < i$, quindi seguendo le frecce gli indici crescono strettamente e non si può tornare indietro. **Fattorizzazione**: per la chain rule $\mathbf{P}(X_1, \dots, X_n) = \prod_i \mathbf{P}(X_i \mid X_1, \dots, X_{i-1})$, e per la scelta dei genitori ogni fattore è uguale a $\mathbf{P}(X_i \mid Parents(X_i))$.

Note:

La procedura garantisce una fattorizzazione *corretta* per qualsiasi ordinamento, ma **non** dice come ottenerne una *compatta*. In pratica i genitori si scelgono con conoscenza del dominio (meglio se causale) oppure si imparano dai dati.

3.2.1.2 Scelta dell'ordinamento

Note:

Perché un ordine causale è preferibile. Ordinare dalle cause agli effetti di solito rende più facile identificare le indipendenze condizionate, stimare le probabilità richieste (le probabilità causali sono più naturali per un esperto) e ottenere una rete compatta con pochi genitori per nodo.

Example 3.2.1 (Ordinamento non causale: M, J, A, B, E)

- $P(J \mid M) = P(J)$? **No** (se Mary chiama, è più probabile che l'allarme suoni e quindi che John chiami) $\Rightarrow M \to J$.
- $P(A \mid J, M) = P(A \mid J)$? $P(A \mid J, M) = P(A)$? **No** $\Rightarrow$ genitori $\{J, M\}$.
- $P(B \mid A, J, M) = P(B \mid A)$? **Sì**. $= P(B)$? **No** $\Rightarrow$ genitore $\{A\}$.
- $P(E \mid B, A, J, M) = P(E \mid A)$? **No**. $= P(E \mid A, B)$? **Sì** $\Rightarrow$ genitori $\{A, B\}$.

Parametri: $1 + 2 + 4 + 2 + 4 = 13$, contro i 10 dell'ordine causale. Inoltre alcune CPT sono innaturali da stimare (es. $P(E \mid B, A)$); con l'ordine M, J, E, B, A si arriva a 31 parametri, tanti quanti la congiunta completa.

Example 3.2.2 (Perché un buon ordinamento conta)

Sapendo che $\mathit{MaryCalls} \perp\!\!\!\perp \mathit{JohnCalls} \mid \mathit{Alarm}$:

- ordine causale A, M, J: $P(A)P(M \mid A)P(J \mid A) \Rightarrow 1 + 2 + 2 = 5$ parametri;
- ordine M, J, A: $P(M)P(J \mid M)P(A \mid M, J) \Rightarrow 1 + 2 + 4 = 7$ parametri.

Rappresentano la stessa distribuzione, ma l'ordine causale rende esplicita l'indipendenza e usa meno parametri.

Note:

Direzione di un arco. Poiché $P(M, J) = P(M)P(J \mid M) = P(J)P(M \mid J)$, sia $M \to J$ sia $J \to M$ sono fattorizzazioni valide della stessa dipendenza, con CPT diverse. Le due frecce **non** possono coesistere: formerebbero un ciclo, e $P(M \mid J)\,P(J \mid M) \neq P(M, J)$ in generale — non c'è un ordine in cui specificare una variabile prima dell'altra. Una rete bayesiana richiede una fattorizzazione non circolare.

Note:

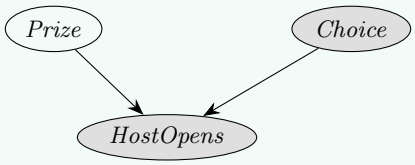
Obiettivo. Non si cerca di rendere ogni variabile indipendente; si cerca un ordinamento e un *piccolo* insieme di genitori diretti per ogni variabile, tali che le altre variabili precedenti non aggiungano informazione una volta noti i genitori.

3.2.2 Esempi di modellazione

3.2.2.1 Monty Hall

Example 3.2.3 (Il problema di Monty Hall)

Siamo in un quiz televisivo davanti a tre porte chiuse; dietro una c'è un premio. Scegliamo la porta di sinistra. Il conduttore, che sa dov'è il premio, apre la porta centrale mostrando che è vuota. Ci viene offerto di cambiare scelta. Conviene?
Variabili: $\mathit{Prize}, \mathit{Choice}, \mathit{HostOpens} \in \{\mathit{left}, \mathit{middle}, \mathit{right}\}$. **Conoscenza del dominio**: il conduttore non apre mai né la porta scelta né quella col premio; se può scegliere tra due porte, sceglie a caso.



La struttura è un **collider**: osservare *HostOpens* rende *Prize* dipendente da *Choice*, ed è questo che rende informativa la porta aperta.
Evidenza: $\mathit{Choice} = \mathit{left}$, $\mathit{HostOpens} = \mathit{middle}$.

Prize	prior	$P(\mathit{HostOpens} = \mathit{middle} \mid \cdot)$	prodotto
left	1/3	1/2	1/6
middle	1/3	0	0
right	1/3	1	1/3

Normalizzando ($1/6 + 0 + 1/3 = 1/2$): $P(\mathit{Prize} = \mathit{left} \mid \mathbf{e}) = 1/3$, $P(\mathit{Prize} = \mathit{right} \mid \mathbf{e}) = 2/3$. **Conviene cambiare.**

Note:

Un'osservazione aggiorna le credenze sulle cause non osservate quando l'osservazione *dipende* da quelle cause.

3.2.2.2 Diagnosi dell'auto

Example 3.2.4 (Diagnosi dell'auto)

Evidenza iniziale: *CarWon'tStart*. I nodi si dividono in: sintomo osservato; variabili **testabili** (luci, indicatore dell'olio, indicatore della benzina, astina); guasti **riparabili** (batteria scarica, alternatore rotto, cinghia rotta, niente olio/benzina, tubo ostruito, motorino rotto); variabili **nascoste** intermedie (batteria morta, non carica, ecc.). Le variabili nascoste aumentano il numero di nodi ma riducono drasticamente i parametri.

3.2.3 Apprendere una rete dai dati

3.2.3.1 Apprendere la struttura

Definition 3.2.2: Structure learning

Quando la conoscenza del dominio non basta a fissare il grafo, si usano i dati per apprendere una struttura plausibile.

- **Metodi constraint-based**: (1) test statistici di indipendenza condizionata; (2) si deduce quali archi devono mancare o possono esserci; (3) si cerca un grafo compatibile con questi vincoli.
- **Metodi score-based**: (1) si definisce uno score che misura quanto una rete spiega i dati penalizzando la complessità; (2) si cerca la struttura con score migliore.

Note:

Limite: strutture diverse possono spiegare ugualmente bene i dati osservazionali; i dati da soli non determinano in generale la direzione causale di ogni arco. La conoscenza del dominio fornisce vincoli (ordine temporale, relazioni causali vietate o richieste). Fissata la struttura, le CPT si stimano dai dati o si chiedono agli esperti.

3.2.3.2 Apprendere i parametri

Note:

Una rete bayesiana specifica una **struttura** ($Parents(X_i)$, da conoscenza del dominio o appresa) e dei **modelli locali** ($\mathbf{P}(X_i \mid Parents(X_i))$, specificati da probabilità o parametri). Da dove vengono i numeri?

Definition 3.2.3: Parameter learning

Data la struttura, il **parameter learning** (forma di *density estimation*) stima le distribuzioni $\mathbf{P}(X_i \mid Parents(X_i))$. Fonti possibili:

- **esperti del dominio**: probabilità elicitate;
- **modelli meccanicistici**: parametri da equazioni fisiche o del dominio;
- **dati**: parametri stimati dalle osservazioni.

Approcci: **maximum likelihood** (parametri che rendono i dati più probabili), **apprendimento bayesiano** (prior sui parametri + dati), **EM** (quando alcune variabili sono nascoste o mancano valori).

Proposition 3.2.1 Stima di massima verosimiglianza di una CPT

Con dati completi, la stima ML di ogni entry di una CPT è la **frequenza relativa osservata**:

$$\hat{P}(X_i = x \mid Parents(X_i) = pa) = \frac{N(X_i = x,\ Parents(X_i) = pa)}{N(Parents(X_i) = pa)}.$$

Grazie alla fattorizzazione, la verosimiglianza si decompone e ogni CPT si stima **separatamente**.

Dimostrazione (caso booleano): Con c casi positivi su N con genitori pa, la verosimiglianza è $L(\theta) = \theta^c(1-\theta)^{N-c}$. Derivando il log: $\frac{c}{\theta} - \frac{N-c}{1-\theta} = 0 \Rightarrow \hat{\theta} = c/N$. ☺

3.2.4 Reti causali

3.2.4.1 Dalla dipendenza alla causalità

Example 3.2.5 (Fuoco e fumo)

Le reti $Fire \to Smoke$ e $Smoke \to Fire$ rappresentano esattamente la stessa congiunta:

$$P(Fire, Smoke) = P(Fire)P(Smoke \mid Fire) = P(Smoke)P(Fire \mid Smoke).$$

I dati osservazionali non le distinguono. Ma sono davvero equivalenti? Accendere un fumogeno non fa scoppiare un incendio.

Definition 3.2.4: Rete causale

Una **rete causale** è una rete bayesiana arricchita con assunzioni causali: è la sottoclasse di reti che ammette solo ordinamenti **causalmente compatibili**. Un arco $X_j \to X_i$ afferma che X_j è un **input diretto del meccanismo** che genera X_i. Permette di ragionare su **interventi**, non solo su osservazioni.

3.2.4.2 Equazioni strutturali

Definition 3.2.5: Equazione strutturale

Per ogni variabile X_i, un'**equazione strutturale** specifica il meccanismo che ne produce il valore:

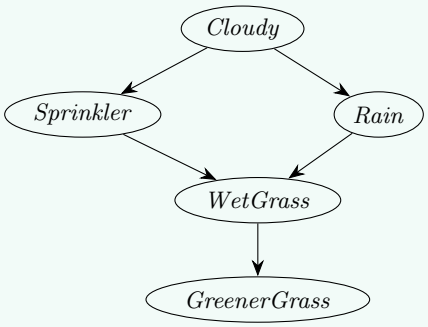
$$X_i = f_i\big(Parents(X_i), U_i\big),$$

dove U_i è una variabile non modellata (termine di errore) che riassume gli altri fattori. L'arco $X_j \to X_i$ è presente **esattamente** quando X_j è un argomento diretto di f_i. Es. $Smoke = f_{Smoke}(Fire, U_{Smoke})$, $Fire = f_{Fire}(U_{Fire})$.

Definition 3.2.6: Invarianza (stabilità) dei meccanismi

Un'equazione strutturale rappresenta un meccanismo causale **autonomo**: rimane invariato rispetto alle osservazioni e ai cambiamenti locali in altre parti dell'ambiente (es. irrigatore disattivato, prato coperto da una tenda: cambia un solo meccanismo, gli altri restano).

Example 3.2.6 (Il prato)



$$C = f_C(U_C), \quad R = f_R(C, U_R), \quad S = f_S(C, U_S), \quad W = f_W(S, R, U_W), \quad G = f_G(W, U_G).$$

3.2.4.3 Interventi e operatore *do*

Definition 3.2.7: Operatore *do* (intervento)

$do(X = x)$ denota un **intervento** che fissa X al valore x dall'esterno del sistema: l'equazione strutturale $X = f_X(Parents(X), U_X)$ viene **sostituita** da $X = x$. **Graficamente**: si rimuovono tutti gli archi *entranti* in X (il suo valore non dipende più dalle cause usuali); gli archi *uscenti* restano (X influenza ancora le sue conseguenze).

Proposition 3.2.2 Fattorizzazione troncata

In una rete causale, l'intervento $do(X_j = \hat{x})$ produce la distribuzione

$$P\big(x_1, \ldots, x_n \mid do(X_j = \hat{x})\big) = \begin{cases} \prod_{i \neq j} P(x_i \mid pa_i) & \text{se } x_j = \hat{x}, \\ 0 & \text{altrimenti,} \end{cases}$$

cioè si elimina dalla semantica globale il fattore $P(x_j \mid pa_j)$.

Example 3.2.7 (Osservare vs. intervenire)

- $P(WetGrass \mid Sprinkler = true)$: "cosa credo sull'erba dopo aver *osservato* che l'irrigatore è acceso?" L'osservazione dà informazione anche sulle sue cause (*Cloudy*, e quindi *Rain*): è probabile che non sia nuvoloso e quindi che non piova.
- $P(WetGrass \mid do(Sprinkler = true))$: "cosa succederebbe all'erba se *accendessi* l'irrigatore?" Si taglia l'arco $Cloudy \to Sprinkler$; *Cloudy* e *Rain* mantengono la distribuzione a priori.

Le due risposte possono differire.

3.3 Rappresentazioni compatte ed estensioni

3.3.1 Distribuzioni canoniche

3.3.1.1 Oltre le CPT

Note:

Limiti delle CPT: una CPT cresce **esponenzialmente** col numero di genitori (n genitori booleani $\Rightarrow 2^n$ righe; con 4 genitori già 16) e diventa **infinita** se il genitore o il figlio è continuo. Le CPT sono pratiche solo per nodi con pochi genitori discreti.

Definition 3.3.1: Distribuzione canonica

Una **distribuzione canonica** specifica $\mathbf{P}(X \mid Parents(X))$ tramite una **forma funzionale compatta** con pochi parametri, invece di elencare una entry per ogni combinazione dei valori dei genitori. La CPT è la rappresentazione generale; le distribuzioni canoniche sono rappresentazioni compatte per strutture ricorrenti. Esempi: nodi deterministici, noisy-OR, modelli ibridi.

3.3.1.2 Nodi deterministici

Definition 3.3.2: Nodo deterministico

Un nodo X è **deterministico** se il suo valore è completamente determinato dai genitori:

$$X = f(Parents(X)).$$

Equivalentemente, noto $Parents(X) = pa$, la distribuzione condizionata assegna probabilità 1 al valore $f(pa)$ (nessuna incertezza).

Example 3.3.1 (Nodi deterministici)

- **Booleano**: $NorthAmerican \equiv Canadian \vee US \vee Mexican$. Una regola logica sostituisce $2^3 = 8$ righe di CPT ($P = 0$ solo se $c = u = m = false$, altrimenti 1): dimensione lineare nei genitori e nessun parametro da stimare.
- **Continuo**: il tasso di variazione del livello d'acqua $\dot{L} = Inflow + Rainfall - Outflow - Evaporation$. Con $I = 5, R = 2, O = 3, E = 1$: $\dot{L} = 3$ con probabilità 1.
- Il prezzo migliore di un'auto è il min dei prezzi dei venditori.

3.3.1.3 Noisy-OR

Note:

Un OR deterministico ($Sneezing \equiv Flu \vee Allergy \vee Cold$, oppure $Alarm \equiv Burglary \vee Earthquake$) è troppo forte: una causa attiva rende l'effetto più probabile, non certo (il sistema d'allarme può essere disattivato, un sensore può guastarsi).

Definition 3.3.3: Noisy-OR

Distribuzione canonica per un effetto booleano Y con cause booleane $X_1, \ldots, X_n$. Ogni causa attiva ha un meccanismo che può attivare Y, ma può **fallire** con **probabilità di inibizione** q_i. Assunzioni:

- tutte le cause possibili sono elencate (vedi *leak node*);
- l'inibizione di ciascuna causa è **indipendente** da quella delle altre.

L'effetto è falso solo se **tutte** le cause attive falliscono:

$$P(Y = false \mid X_1, \ldots, X_n) = \prod_{i\,:\,X_i = true} q_i, \qquad P(Y = true \mid X_1, \ldots, X_n) = 1 - \prod_{i\,:\,X_i = true} q_i.$$

$p_i = 1 - q_i$ è detta **link probability** (probabilità che X_i da sola causi Y).

Definition 3.3.4: Leak node

Nel noisy-OR base, se nessuna causa modellata è attiva l'effetto non può verificarsi: $P(Y = \mathit{true} \mid X_1 = \cdots = X_n = \mathit{false}) = 0$. Per superare il limite si aggiunge un **leak node**: un genitore aggiuntivo **sempre attivo** che rappresenta tutte le cause non modellate.

Proposition 3.3.1 Parametri del noisy-OR

Il noisy-OR specifica l'intera CPT di Y con n parametri (uno per causa) invece di 2^n: il numero di parametri è **lineare** nel numero di genitori.

Example 3.3.2 (Allarme noisy-OR)

$p_B = 0.95$, $p_E = 0.30 \Rightarrow q_B = 0.05$, $q_E = 0.70$.

B	E	$P(\mathit{Alarm} = \mathit{true} \mid B, E)$
F	F	0
T	F	$p_B = 0.95$
F	T	$p_E = 0.30$
T	T	$1 - q_B q_E = 1 - 0.05 \cdot 0.70 = 0.965$

Example 3.3.3 (Febbre (noisy-OR completo))

$q_{cold} = 0.6$, $q_{flu} = 0.2$, $q_{malaria} = 0.1$:

Cold	*Flu*	*Malaria*	$P(\mathit{fever})$	$P(\neg \mathit{fever})$
F	F	F	0.0	1.0
F	F	T	0.9	0.1
F	T	F	0.8	0.2
F	T	T	0.98	$0.02 = 0.2 \times 0.1$
T	F	F	0.4	0.6
T	F	T	0.94	$0.06 = 0.6 \times 0.1$
T	T	F	0.88	$0.12 = 0.6 \times 0.2$
T	T	T	0.988	$0.012 = 0.6 \times 0.2 \times 0.1$

Si danno solo i 3 valori q_i; le altre righe si calcolano.

Note:

Caso reale: CPCS (Pradhan et al., UAI 1994): rete bayesiana per la medicina interna con **448 nodi e 908 archi**, modellata con **noisy-MAX** (generalizzazione del noisy-OR a variabili multivalore) più probabilità di leak. Bastano 8.254 valori invece dei 133.931.430 di una rete con CPT complete.

3.3.2 Reti ibride

3.3.2.1 Discretizzazione o modelli parametrici

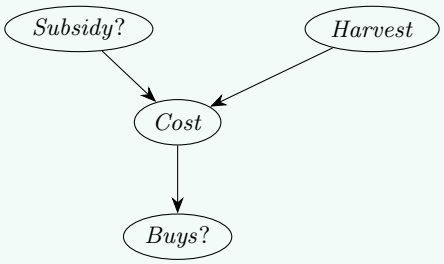
Definition 3.3.5: Rete bayesiana ibrida

Una rete che contiene sia variabili **discrete** sia **continue**. Le distribuzioni locali possono combinare CPT, densità condizionate e altre forme parametriche compatte. Due opzioni:

1. **Discretizzazione**: si sostituiscono le variabili continue con intervalli e si usano CPT. Trade-off: pochi intervalli perdono informazione, molti producono CPT enormi.
2. **Famiglie parametriche canoniche** con un numero finito di parametri, per (a) figlio continuo con genitori continui e/o discreti, e (b) figlio discreto con genitori continui.

Example 3.3.4 (Raccolto e acquisto)

Il costo (*Cost*, continuo) dipende dalla quantità raccolta (*Harvest*, continua) e dalla presenza di un sussidio (*Subsidy*?, discreta); il costo influenza la decisione di acquisto (*Buys*?, discreta). Servono $P(Cost \mid Harvest, Subsidy?)$ e $P(Buys? \mid Cost)$.



3.3.2.2 Figlio continuo: modello lineare gaussiano

Definition 3.3.6: Densità condizionata per un figlio continuo

Per un figlio continuo Y, la distribuzione locale è una densità condizionata $p(y \mid Parents(Y))$: per ogni assegnazione fissata dei genitori è non negativa e integra a 1. Si definisce una densità separata per ogni assegnazione dei genitori *discreti*; la densità può poi dipendere dai valori dei genitori *continui*.

Definition 3.3.7: Modello lineare gaussiano

Il figlio ha distribuzione gaussiana la cui media varia **linearmente** con i genitori continui, con varianza fissa:

$$Cost = a_t\, Harvest + b_t + \varepsilon_t, \qquad \varepsilon_t \sim \mathcal{N}(0, \sigma_t^2),$$

cioè, fissati $Harvest = h$ e $Subsidy? = t$,

$$Cost \mid (h,t) \sim \mathcal{N}(a_t h + b_t,\ \sigma_t^2), \qquad \mathbb{E}[Cost \mid h,t] = a_t h + b_t.$$

a_t: come cambia il costo atteso al crescere del raccolto (pendenza, negativa perché più offerta abbassa il prezzo); b_t: intercetta; σ_t^2: incertezza residua. I parametri possono differire per $t = true$ e $t = false$.

Proposition 3.3.2 Reti lineari gaussiane

- Se **tutte** le variabili sono continue con distribuzioni lineari gaussiane, la congiunta è una **gaussiana multivariata**: $\mathbf{P}(X_1, \ldots, X_n) = \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$.
- Se ci sono anche genitori discreti (rete **gaussiana condizionata**), per ogni assegnazione $\mathbf{D} = \mathbf{d}$ delle

discrete la distribuzione delle continue è una gaussiana multivariata.

- Se i genitori discreti non sono osservati si ottiene una **miscela di gaussiane**: $P(c \mid h) = \sum_t P(c \mid h, t)\, P(t)$.

Note:

L'assunzione di linearità implica che il costo diventi negativo per raccolti molto grandi: il modello è ragionevole solo su un range limitato di *Harvest*.

3.3.2.3 Figlio discreto: probit e logit

Definition 3.3.8: Figlio discreto con genitore continuo

Per un figlio discreto Y con genitori continui $\mathbf{X}$ si specifica $P(Y = y \mid \mathbf{X} = \mathbf{x})$ per ogni $\mathbf{x}$; non potendo elencarli in una CPT finita, si usa una funzione con pochi parametri. Una regola deterministica (*Buys*? sse *Cost* $< \mu$) è troppo rigida: serve una **soglia morbida** (soft threshold).

Definition 3.3.9: Modello probit

$$P(Buys? = true \mid Cost = c) = \Phi\left(\frac{\mu - c}{\sigma}\right),$$

dove Φ è la funzione di ripartizione (CDF) della gaussiana standard, μ è il costo a cui la probabilità d'acquisto è 0.5 e σ controlla quanto è graduale la transizione.

Proposition 3.3.3 Giustificazione del probit

Se il processo decisionale ha una soglia *rigida* T ("compro sse $c \le T$") ma la posizione della soglia è soggetta a rumore gaussiano, $T \sim \mathcal{N}(\mu, \sigma^2)$, allora la probabilità d'acquisto è esattamente il modello probit.

Dimostrazione: $P(buys \mid c) = P(T \ge c) = 1 - \Phi\left(\frac{c-\mu}{\sigma}\right) = \Phi\left(\frac{\mu-c}{\sigma}\right)$, per la simmetria $1 - \Phi(z) = \Phi(-z)$ della gaussiana standard.

Definition 3.3.10: Modello logit (logistico)

Usa la funzione logistica (sigmoide) $1/(1 + e^{-x})$:

$$P(Buys? = true \mid Cost = c) = \frac{1}{1 + \exp\left(-2\,\frac{-c+\mu}{\sigma}\right)}.$$

Note:

Probit e logit hanno forma simile, ma il logit ha **code più lunghe**. Il probit si adatta spesso meglio a situazioni reali; il logit è più comodo matematicamente ed è molto usato in machine learning.

3.3.3 Reti bayesiane dinamiche

3.3.3.1 Stati e traiettorie

Definition 3.3.11: Stato, variabili template, traiettoria

- Lo **stato** del sistema al tempo t è un insieme di variabili $X^{(t)} = \{X_1^{(t)}, \dots, X_n^{(t)}\}$.
- Una **variabile template** X_i denota la stessa quantità a ogni passo; $X_i^{(t)}$ è la sua istanza al tempo t.
- Una **traiettoria** è una sequenza completa di stati $\left(X^{(0)}, X^{(1)}, \dots, X^{(T)}\right)$.

Definition 3.3.12: Rete bayesiana dinamica (DBN)

Una **DBN** è una rappresentazione compatta, basata su template, di una distribuzione di probabilità sull'evoluzione di un sistema nel tempo, cioè sulle traiettorie: $P\left(X^{(0)}, \dots, X^{(T)}\right)$. Invece di disegnare una rete nuova per ogni istante, si specifica una struttura una volta e la si ripete.

3.3.3.2 Template a due slice

Definition 3.3.13: Assunzione di Markov del primo ordine

Lo stato al passo successivo dipende solo dallo stato corrente:

$$P\left(X^{(t+1)} \mid X^{(0)}, \dots, X^{(t)}\right) = P\left(X^{(t+1)} \mid X^{(t)}\right).$$

Definition 3.3.14: Template a due slice (2-TBN)

Specifica le dipendenze tra un passo t e il successivo $t+1$, più una rete iniziale per $X^{(0)}$. Viene "srotolato" (unrolled) ripetutamente per rappresentare traiettorie di lunghezza arbitraria. Si assume implicitamente che la transizione sia la stessa a ogni passo (**stazionarietà**).

Theorem 3.3.1 Distribuzione su una traiettoria

Una DBN del primo ordine specifica

$$P\left(X^{(0)}, \dots, X^{(T)}\right) = P\left(X^{(0)}\right) \prod_{t=0}^{T-1} P\left(X^{(t+1)} \mid X^{(t)}\right).$$

Dimostrazione: Chain rule sull'ordinamento temporale: $P(X^{(0)}, \dots, X^{(T)}) = P(X^{(0)}) \prod_{t=0}^{T-1} P(X^{(t+1)} \mid X^{(0)}, \dots, X^{(t)})$; per l'assunzione di Markov ogni fattore si riduce a $P(X^{(t+1)} \mid X^{(t)})$.

Example 3.3.5 (Meteo e traffico)

$X^{(t)} = \{Weather^{(t)}, Traffic^{(t)}\}$. Traiettoria $(sunny, low), (rain, high), (rain, high)$ con $P(X^{(0)}) = 0.30$, transizioni 0.40 e 0.50:

$$P(\text{traiettoria}) = 0.30 \cdot 0.40 \cdot 0.50 = 0.06.$$

3.3.4 Oltre le reti bayesiane: reti di Markov

3.3.4.1 Modelli grafici diretti e non diretti

Definition 3.3.15: Modello grafico probabilistico (PGM)

Usa un grafo per rappresentare in modo compatto una distribuzione congiunta.

	Rete bayesiana	Rete di Markov
Grafo	diretto	non diretto
Parametri	distribuzioni condizionate	fattori di compatibilità
Relazioni	causali / generative	simmetriche / vincoli

Il modello non diretto è naturale quando non c'è una direzione d'influenza (pixel vicini hanno colori simili; due persone tendono ad avere opinioni compatibili).

3.3.4.2 Definizione ed esempio

Definition 3.3.16: Rete di Markov

Una **rete di Markov** è un PGM non diretto la cui congiunta è definita da **fattori** non negativi (funzioni di compatibilità) ϕ_C sulle clique C del grafo:

$$P(\mathbf{X}) = \frac{1}{Z} \prod_{C \in \mathcal{C}} \phi_C(\mathbf{X}_C), \qquad Z = \sum_{\mathbf{x}} \prod_{C \in \mathcal{C}} \phi_C(\mathbf{x}_C),$$

dove Z è la costante di normalizzazione (*partition function*). I valori dei fattori sono **punteggi**, non probabilità.

Example 3.3.6 (Opinioni (Alice, Bob, Charlie, Debbie))

Quattro persone su un ciclo $A - B - C - D - A$; ogni variabile ha valori 0 ("a favore") e 1 ("contro"). Fattori:

$\phi_1(A,B)$		
a^0	b^0	30
a^0	b^1	5
a^1	b^0	1
a^1	b^1	10

$\phi_2(B,C)$		
b^0	c^0	100
b^0	c^1	1
b^1	c^0	1
b^1	c^1	100

$\phi_3(C,D)$		
c^0	d^0	1
c^0	d^1	100
c^1	d^0	100
c^1	d^1	1

$\phi_4(D,A)$		
d^0	a^0	100
d^0	a^1	1
d^1	a^0	1
d^1	a^1	100

Punteggio globale: $w(a,b,c,d) = \phi_1(a,b)\,\phi_2(b,c)\,\phi_3(c,d)\,\phi_4(d,a)$.

- (a^0, b^1, c^1, d^0): $5 \cdot 100 \cdot 100 \cdot 100 = 5\,000\,000$ (soddisfa tre forti preferenze locali: $b^1 = c^1$, $c^1 \neq d^0$, $d^0 = a^0$);
- (a^0, b^0, c^0, d^0): $30 \cdot 100 \cdot 1 \cdot 100 = 300\,000$ (Charlie e Debbie concordano, ma ϕ_3 lo penalizza).

Dopo la normalizzazione: $P(a,b,c,d) = w(a,b,c,d)/Z$.